Implementacija spletnega pajka

Adam Prestor, Lojze Žust
ap2408@student.uni-lj.si, lojze.zust@student.uni-lj.si

1 Uvod

Spletni pajek je program, ki se sistematično premika po svetovnem spletu. Običajno se uporablja z namenom izgradnje indeksa spletnih strani, ki omogočajo spletnim brskalnikom, kot so Google, da bolj učinkovito preiskujejo splet. Eden izmed bolj znanih spletnih pajkov je Googlebot - Googlov spletni pajek.

V tej seminarski nalogi smo implementirali spletnega pajka, ki se sprehaja po spletišču *gov.si*. Pri implementaciji smo se držali podanih navodil za implementacijo, ki jih bomo podrobneje opisali v naslednjih poglavjih.

2 Metodologija

Za implementacijo smo uporablili programski jezik Python in postgresql bazo.

2.1 Razširitev baze

Osnovni strukturi baze smo dodali nekaj polj, za lažje izvajanje pajka. Tabeli *site* smo dodali polji *delay* in *next_allowed_time*, tabeli *page* pa smo dodali polje *html_content_hash*.

2.2 Inicializacija

Plazenje vedno začne glavni proces in sicer z dodajanjem začetnih strani v frontir. Poleg tega pogleda v bazo, če obstajajo strani brez oznake, te strani so namreč obtičale sredi obdelave ali pa je prišlo pri njih do napake, ter jih prestavi v frontir. Ko konča, pogleda koliko procesov naj uporabi. Slednjo informacijo dobi iz argumenta klica funkcija *-n*. Prenastavljena vrednost je 8. Vsak proces posebej potem predstavlja svojega delavca, ki vzema povezave iz frontira in jih ustrezno obdela.

2.3 Plazenje

Plezanje se dogaja znotraj novo nastalih procesov. Vsak delavec ima svoj Chrome gonilnik, ki ga potrebuje knjižnica Selenium, ki ga uporablja za generiranja vsebine strani. Z gonilnikom potem delavec vstopi v zanki, ki se izvaja do neskončnosti, znotraj katere najprej poskusi vzeti stran iz frontirja. Ker tu lahko pride do primera, da bi lahko več delavcev dobilo isto povezavo, smo uporabili ključavnico. Tako do frontirja dostopa le en delavec na enkrat.

2.3.1 Frontir

Frontir deluje po principu FIFO (first-in-first-out), kar pomeni, da pajek deluje po principu *breadth first search*. To dosežemo tako, da dovoljene povezave v frontirju uredi po id polju, saj imajo povezave, ki so bile dodane prej, nižji id.

Kaj pomeni dovoljena povezava? Vsaka povezava v bazi je povezana z domeno, na kateri jo najdemo. Vsaka domena ima shranjeno, kdaj bomo lahko naslednjič dostopali do nje. Stran je dovoljena, če lahko dostopamo do domene na kateri stran je. Ko stran pridobimo iz frontirja posodobimo tudi domeno in s tem spremenimo dovoljeni čas naslednjega obiska na domeni. Ta se izračuna tako, da sešteje zakasnitev domene in obisk trenutne strani.

Če v frontirju ni dovoljene strani, frontir pa še vedno ni prazen, vrnemo izjemo *FrontierNotAvailableException*. V tem primeru delavec počaka 2 sekundi, da se domene sprostijo. Če pa je frontir prazen, vrnemo *EmptyFrontierException*, v katerem primeru delavec počaka 10 sekund, da se morebitne strani v vrsti obdelajo. Če je frontir še vedno prazen, potem lahko sklepamo, da smo prišli do konca plezanja.

2.3.2 Domena

Ko delavec pride na stran, najprej preveri, če domena, na kateri je stran, že obstaja zapisana v bazi. Če je še ni, jo doda. Pri tem poskusi pridobiti tudi *robots.txt* in *sitemap*, če obstajata. Iz *robots.txt* prebere tudi željeno zakasnitev obiskev, ter si jo shrani. Če slednjega ne more prebrati, potem se nastavi na privzeto vrednost 5 sekund. Poleg tega

smo dodali polje, ki si shrani čas naslednjega dovoljenega obiska na domeni.

2.3.3 Obdelava vsebine strani

Preden sploh začnemo obdelovati vsebino strani, se prepričamo, če gre sploh za html vsebino in če do nje lahko dostopamo. Zato najprej pošljemo head zahtevek s knjižnico *requests* na stran in iz njega izluščimo status in tip. Če gre za napako, potem strani spremenimo tip v bazi na *null* in nadaljujemo s plazenjem naprej. Če ne gre za html, potem zapišemo, da gre za binarno stran.

Če smo naleteli na html stran brez napake, potem uporabimo Selenium knjižnico, da generiramo vsebino strani. Iz strani nato izluščimo povezave iz href atributa in onclick funkcij. Te povezave ločimo na običajne in binarne, binarne se končajo s končnicami, ki so zapisane v tabeli *data_type*. Prav tako izliščimo slike iz slikovnih elementov vsebine, kjer preberemo vsebino atributa src.

2.3.4 Preverjanje duplikatov

Vsebino, ki smo jo dobili z obiskane strani, potem z zgoščevalno funkcijo stisnemo in pogledamo, če je enaka kateri drugi strani, ki smo jo obdelali v preteklosti. Če se s katero ujema, potem stran označimo kot duplikat, dodamo povezavo na stran, s katero se je ujemala in nadaljujemo plazenje.

2.3.5 Dodajanje vsebine in strani

Vsebino strani shranimo v bazo, skupaj s statusom in tipom vsebine.

Binarne povezave in povezave do slik shranimo v bazo direktno. Edina stvar, ki jo moramo najti je tip, ki ga dobimo iz končnice, če ga le lahko, pri slikah ni nujno, da bodo povezave imele smiselno končnico. Končnico dobimo z razrezom povezave po pikah, kjer zadnji del predstavlja končnico. Če je ta predolga, potem končnice nismo uspeli pridobiti in ponastavimo vrednost tipa na prazen niz.

Pri dodajanju povezav na nove strani, pa pred dodajanjem v bazo preverimo, če prihaja iz *gov.si* domene. Stran potem poskusimo dodati v frontir, v bazi se preveri, če je url že zapisan in če *robots.txt* dovoljuje dostop. V nasprotnem primeru strani ne dodamo v frontir. Prav tako pa si v bazo zapišemo še povezavo med stranema.

To je bil še zadnji korak obdelave strani. Sedaj je delavec pripravljen na obdelavo nove strani in cikel se ponovi.

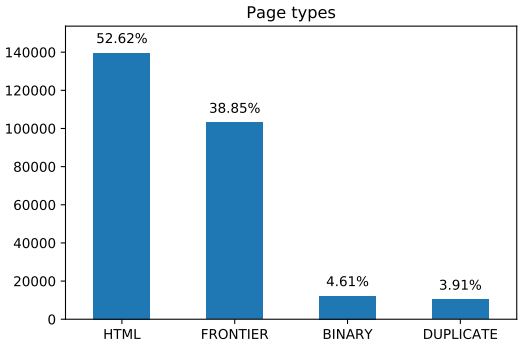

Slika 1: Porazdelitev števila strani glede na tip.

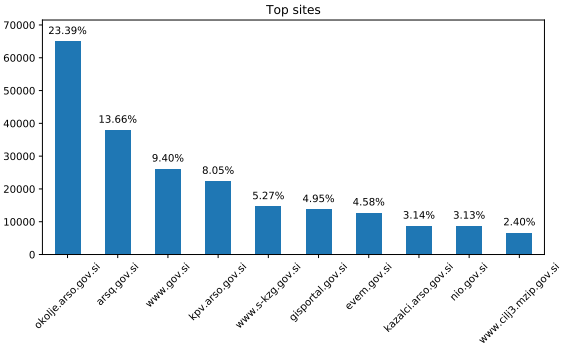

Slika 2: Poradelitev števila strani po najpogostejših 10 domenah.

3 Rezultati

Spletni pajek se je izvajal skupno 62 ur z 8 procesi hkrati. Toliko časa smo ga pustili, ker smo mislili, da bo v tem času lahko preiskal celotno spletišče na domeni *gov.si*, vendar temu ni bilo tako, zato smo ga bili na koncu primorani prisilno ustaviti.

V podatkovni bazi je bilo ob zaustavitvi skupaj 277 954 strani. Od tega so velik del še vedno predstavljale strani v frontirju (skoraj 40%). Prikaz porazdelitve strani po različnih kategorijah je prikazan na Sliki 1. Pajek je detektiral in označil 10 385 strani, ki predstavljajo duplikate in 12 243 strani, ki v resnici predstavljajo binarne podatke. V nadaljevanju analize opazujemo strani, katerih vsebina je bila uspešno zajeta in označena kot HTML.

Med plazenjem je pajek zaznal 354 različnih poddomen. Na Sliki 2 je prikazano število strani, ki pripadajo desetim najpogostejšim domenam. Le dve domeni sta imeli v robots.txt definiran crawl-time drugačen od 5.

Analizirali smo tudi statisiko povezav. V Tabeli 1 in na Sliki 3 so prikazane osnovne statistike števila vhodnih in izhodnih po-

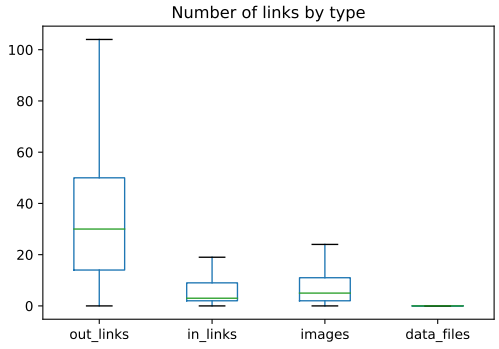

Slika 3: Število različnih povezav in vsebin s prikazom škatle z brki. Osamelci niso prikazani. Povprečna stran vsebuje več izhodnih povezav, kot vhodnih. Vendar obstaja majhen del strani z ogromnim številom vhodnih povezav, ki uravnovesijo povprečno število vhodnih in izhodnih povezav.

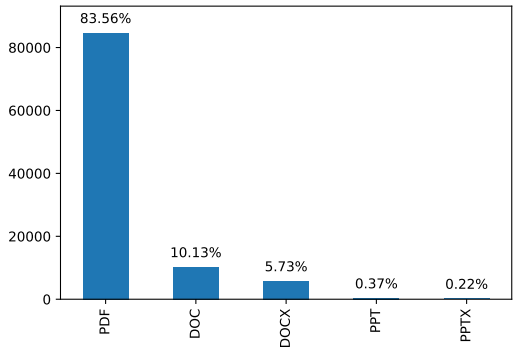

Slika 4: Porazdelitev različnih tipov datotek. Daleč največji delež predstavljajo datoteke PDF.

vezav, slik in datotek. Poiskali smo strani z največjim številom posameznih povezav. Največje število izhodnih povezav vsebuje stran *http://evem.gov.si/info/podpogoji/*. Največ srtani kaže na stran *http://www.arso.gov.si/* Največ slik vsebuje stran *http://meteo.arso.gov.si/met/en/watercycle/maps/growa_si*, ki vsebuje povezave na ogromno število slik modelov. Največje število datotek vsebuje stran *https://www.gov.si/drzavni-organi/ministrstva/ministrstvo-za-kmetijstvo-gozdarstvo-in-prehrano/o-ministrstvu/seznami-certificiranih-proizvajalcev/*.

	AVG	MAX
Št. vhodnih povezav	61.57	43660
Št. izhodnih povezav	64.36	2309
Št. slik	6.74	412
Št. datotek	0.67	786

Tabela 1: Povprečje in maksimalna vrednost različnih tipov povezav posameznih zajetih strani.

Podrobneje smo pogledali tudi porazdelitev števila datotek po tipih (glej Sliko 4). Daleč največ datotek je tipa PDF, sledijo Wordove datoteke, zelo majhen delež pa je PowerPoint datotek.

Zaradi ogromne velikosti končne baze strani, smo se odločili raziskati tudi velikost posameznih strani glede na vsebino HTML (glej Sliki 5 in 6). Velikost največje strani v bazi je skoraj 5 MB. V splošnem je strani večjih od 1 MB v bazi zelo malo. Veliko večino strani predstavljajo majhne datoteke. Kljub temu pa velike datoteke prispevajo velik del k skupni velikosti. Največjih 20 000 strani prispeva skoraj tretjino skupne velikosti strani.

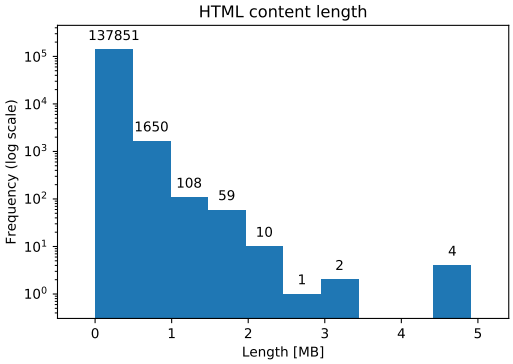

Slika 5: Histogram velikosti HTML vsebine strani v logaritemski skali. Porazdelitev je močno nagnjena proti majhnim stranem.

4 Zaključek

V tej seminarski nalogi smo razvili učinkovitega pajka, ki je sposoben paralelnega zajema strani, upoštevanja etičnih navodil spletnih strani (robots.txt), zaznavanja duplikatov. Z njim smo zajeli veliko število strani z vladnih spletnih strani in jih analizirali. Pajek je deloval robustno in brez prekinitev, zajete strani pa so bile smiselne. V prihodnje bi ga bilo mogoče nadgraditi z delnim preverjanjem duplikatov, ponovnim preverjanjem neuspešno zajetih strani.

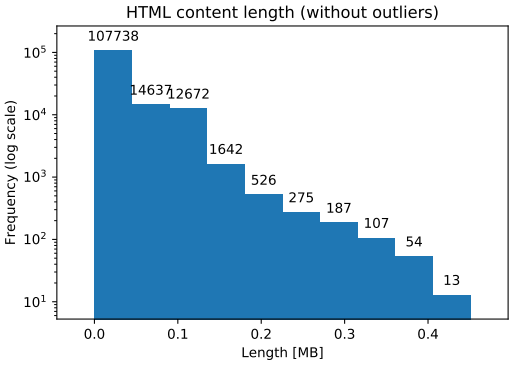

Slika 6: Histogram velikosti HTML vsebine strani v logaritemski skali. Prikaz brez osamelcev. Prikazane so le strani manjše od 0.5 MB.